

Análisis Series de Tiempo: Precio del Oro

Nicolás Méndez Gutiérrez - Christian Martinez

2025-06-16

Contents

1	Descripción del dataset	5
1.1	Estructura de los datos	5
2	Objetivo	7
3	Justificación	9
4	Análisis Exploratorio de Datos	11
4.1	Análisis de promedio móvil, rezagos y estacionalidad	14
5	Pronóstico de Series de Tiempo Holt-Winters	21
5.1	Aplicar el modelo de Holt-Winters	21
5.2	Evaluar el ajuste del modelo	22
5.3	Pronostico con Holt-Winters	30
5.4	Aplicación de suavizado exponencial simple	31
5.5	Comparación de modelos	31
5.6	Conclusiones	32
6	Pronóstico con modelo ARIMA	33
7	Algoritmo de Facebook's Prophet	35
8	Redes Neuronales	37
9	Fuentes	39

Chapter 1

Descripción del dataset

Este conjunto de datos contiene registros históricos del precio del oro desde el 31 de diciembre de 2013 hasta el 5 de noviembre de 2024, extraídos del mercado MCX. Se trata de un dataset útil para el análisis de series temporales y la predicción de tendencias del precio del oro.

1.1 Estructura de los datos

El dataset incluye 2806 entradas y múltiples columnas con información clave:

- Date: Fecha de transacción.
- Open: Precio de apertura del mercado
- High: Precio más alto alcanzado en el día
- Low: Precio más bajo alcanzado en el día
- Price: Precio de cierre del día
- Volume: Cantidad de transacciones realizadas
- Chg%: Variación porcentual del precio respecto al día anterior.

Chapter 2

Objetivo

Con este dataset se busca analizar el comportamiento histórico de los precios del oro con el objetivo de identificar tendencias significativas a lo largo del tiempo. Además, permite aplicar modelos estadísticos y de aprendizaje automático para predecir movimientos futuros del mercado, proporcionando herramientas útiles para comprender las dinámicas de este activo financiero y apoyar la toma de decisiones en contextos económicos y de inversión.

Chapter 3

Justificación

El dataset de precios diarios del oro es altamente adecuado para la aplicación de técnicas de análisis de series de tiempo debido a las siguientes características:

1. Datos de tiempo ordenados
 - La variable Date proporciona una secuencia cronológica continua sin valores faltantes, lo que facilita la modelación de tendencias y patrones temporales.
 - La periodicidad diaria permite estudiar el comportamiento del mercado con alta resolución temporal.
2. Evolución de variable dependiente
 - La columna Price representa el precio de cierre, una métrica clave para analizar la evolución del valor del oro a lo largo del tiempo.
 - Al ser una serie numérica con cambios graduales y picos específicos, es ideal para aplicar modelos predictivos como ARIMA, modelos de suavizamiento exponencial y redes neuronales recurrentes.
3. Factores Exógenos y Multivariabilidad
 - Las variables Open, High, Low y Volume permiten estudiar la influencia de distintos factores sobre la variación del precio, enriqueciendo el análisis.
 - La columna Chg% proporciona información sobre volatilidad y puede usarse para identificar momentos de alta inestabilidad en el mercado.
4. Aplicabilidad Real y Relevancia Económica
 - El oro es un activo financiero de gran importancia en la economía global, por lo que analizar sus precios a lo largo del tiempo tiene aplicaciones prácticas en predicción de tendencias, evaluación de riesgos y toma de decisiones de inversión.

- Permite la identificación de patrones estacionales, ciclos de mercado y efectos de eventos económicos en la fluctuación del precio.

5. Calidad de los datos

- Con 2806 registros sin valores faltantes, el dataset proporciona información confiable para entrenar modelos sin la necesidad de una limpieza exhaustiva.
- La estabilidad en la estructura del dataset facilita la aplicación de metodologías estadísticas y de machine learning.

En conclusión este dataset es ideal para estudios de series de tiempo, ya que permite aplicar modelos predictivos, evaluar la influencia de factores exógenos y analizar tendencias económicas con datos sólidos y completos.

Chapter 4

Análisis Exploratorio de Datos

Se importa el dataset cuyos primeros registros se muestran a continuación.

```
# A tibble: 6 x 7
  Date      Price Open  High   Low Volume `Chg%`
<date>    <dbl> <dbl> <dbl> <dbl> <dbl>   <dbl>
1 2024-11-06 77030 78300 78570 77030     0  -1.86
2 2024-11-05 78490 78224 78670 78160     0   0.11
3 2024-11-04 78401 78498 78642 78237     0  -0.54
4 2024-11-01 78829 78650 78887 78550     0   0.64
5 2024-10-31 78326 79264 79999 77803    90  -1.17
6 2024-10-30 79257 79119 79375 78888   130   0.5
```

A continuación se presenta un resumen de medidas descriptivas.

Variable type: Date

Table 4.1: Data summary

Name	datos
Number of rows	2806
Number of columns	7
Column type frequency:	
Date	1
numeric	6
Group variables	
None	

skim_variable	n_missing	complete_rate	min	max	median	n_unique
Date	0	1	2014-01-01	2024-11-06	2019-05-27	2806

Variable type: numeric


skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50
Price	0	1	40699.89	13828.62	24545.00	29128.00	32980.00
Open	0	1	40700.22	13826.94	24583.00	29103.75	33000.00
High	0	1	40917.78	13900.47	24635.00	29261.25	33220.50
Low	0	1	40482.31	13756.09	24470.00	28974.00	32890.00
Volume	0	1	12529.58	10649.99	0.00	6282.50	10770.00
Chg%	0	1	0.04	0.83	-5.98	-0.38	0.04

Se explora la existencia de datos faltantes.


Date	Price	Open	High	Low	Volume	Chg%
0	0	0	0	0	0	0

Se realizan gráficos para observar tendencias a lo largo del tiempo de:





- Cambios porcentuales



- Comparación del valor máximo vs mínimos del día

4.1 Análisis de promedio móvil, rezagos y estacionalidad

4.1.1 Promedio móvil

Se agrega un promedio móvil de 7 días, es decir, de manera semanal ya que muchos mercados (como el oro, acciones, productos básicos) tienden a mostrar variaciones semanales (por factores como fin de semana, cierres de mercado, ciclos de noticias, etc.)




Se hacen las siguientes observaciones:

- La serie muestra una tendencia creciente de largo plazo, especialmente desde 2019 en adelante.
- 2013 - 2018: El precio del oro estuvo relativamente estable o ligeramente a la baja, con pequeñas fluctuaciones.
- 2019 - 2020: Se observa un fuerte crecimiento, con un aumento pronunciado en el precio.
- 2020 - 2021: Hay una corrección o caída parcial, después de un máximo.
- 2021 - 2025: Retoma una tendencia alcista constante con algunos ciclos de subida y bajada.
- Se identifican momentos donde la curva cambia de pendiente (subidas abruptas o correcciones), que pueden estar asociadas a eventos macroeconómicos.

4.1. ANÁLISIS DE PROMEDIO MOVIL, REZAGOS Y ESTACIONALIDAD¹⁵


4.1.2 Rezagos (lags)



Se realizan las siguientes observaciones:

- El precio del oro no cambia drásticamente de un día para otro; más bien tiende a seguir la misma trayectoria.
- Hay baja volatilidad diaria relativa (aunque a largo plazo se observaron tendencias importantes).

4.1.3 Estacionalidad



- En la primera porción de la gráfica, se observa el comportamiento de la variable precio a lo largo del tiempo.
- La segunda porción, Seasonal, muestra cómo varía sistemáticamente a lo largo del año.
- La tercera porción, muestra la Tendencia a largo plazo.
- Finalmente, se observa en la porción de Remainder el ruido no se explicado por la estacionalidad.

De la gráfica, se realizan las siguientes observaciones:

- Se aprecia claramente la tendencia creciente fuerte, especialmente desde el año 2020 en adelante.
- El componente estacional muestra ciclos repetitivos con una frecuencia regular de picos y valles aproximadamente cada año. La amplitud del patrón estacional es pequeña en comparación al nivel del precio.

Se verifica la estacionalidad.

Augmented Dickey-Fuller Test

```
data: serie_ts
Dickey-Fuller = -1.2393, Lag order = 14, p-value = 0.9002
alternative hypothesis: stationary
```


- El ADF test evalúa la hipótesis nula de que una serie no es estacionaria

4.1. ANÁLISIS DE PROMEDIO MOVIL, REZAGOS Y ESTACIONALIDAD¹⁷

(tiene raíz unitaria), frente a la hipótesis alternativa de que sí es estacionaria.

- Con un p-valor tan alto (0.9002), la evidencia estadística indica que la serie `ts_price`:
 - No tiene media ni varianza constante en el tiempo.
 - Tiene una tendencia persistente, como ya se vio en la descomposición STL.
 - No es apta para modelado directo con ARIMA u otras técnicas que requieren estacionariedad, a menos que se transforme.

4.1.4 Diferenciación de primer orden



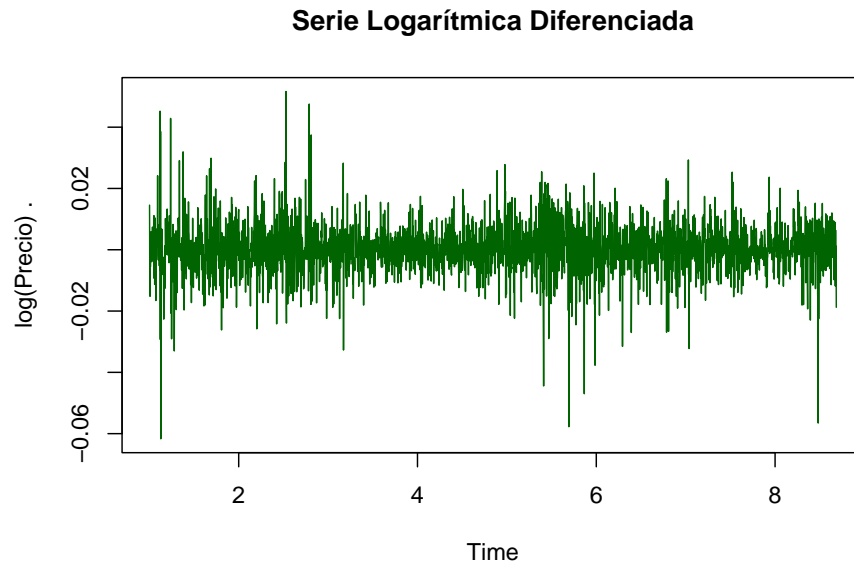
Prueba ADF tras la diferenciación:

Augmented Dickey-Fuller Test

```
data: ts_diff1
Dickey-Fuller = -15.197, Lag order = 14, p-value = 0.01
alternative hypothesis: stationary
```

- p-value = 0.01: Significa que podemos rechazar la hipótesis nula de no estacionariedad.
- El estadístico Dickey-Fuller altamente negativo (-15.197) indica una fuerte evidencia de estacionariedad.

4.1.5 Transformación logarítmica + diferencia



- La serie resultante oscila en torno a cero, lo cual indica estacionariedad en media.
- No hay una tendencia visible: el promedio es constante.
- La dispersión (volatilidad) se ve bastante estable a lo largo del tiempo → varianza constante, o al menos más homogénea que la serie original.
- Hay algunos picos puntuales que pueden ser eventos de mercado extremos, pero no afectan la estructura general.
- La serie logarítmica diferenciada cumple con los requisitos clave de una serie estacionaria: media constante, varianza relativamente constante y ausencia de tendencia.
- Es altamente recomendable trabajar con esta serie transformada para fines de modelado, predicción o análisis estadístico.

ADF para log-diff:

Augmented Dickey-Fuller Test


```
data: ts_log_diff
Dickey-Fuller = -14.322, Lag order = 14, p-value = 0.01
alternative hypothesis: stationary
```

- Se aplicó la transformación logarítmica y diferenciación de primer orden a la serie del precio del oro con el objetivo de controlar la tendencia creciente y la variabilidad no constante observadas en la serie original.

4.1. ANÁLISIS DE PROMEDIO MOVIL, REZAGOS Y ESTACIONALIDAD¹⁹

- La prueba de Dickey-Fuller aumentada aplicada a la serie transformada ($\text{diff}(\log(\text{Precio}))$) arrojó un estadístico de -14.322 y un p-valor inferior a 0.01, lo cual permite rechazar la hipótesis nula de no estacionariedad.
- Por tanto, se concluye que la serie logarítmica diferenciada es estacionaria, lo cual justifica su uso en procesos de modelado como ARIMA, SARIMA o técnicas de pronóstico más avanzadas. Esta transformación también normaliza la escala de los cambios, permitiendo interpretar los resultados en términos de retornos porcentuales diarios.

4.1.6 Visualización comparativa




- La serie original del precio del oro presenta una tendencia creciente y varianza heterogénea, por lo que no cumple los requisitos de estacionariedad.
- La diferenciación de primer orden elimina la tendencia, estabilizando la media pero no completamente la varianza.
- Al aplicar una transformación logarítmica seguida de una diferencia, se consigue una serie que oscila alrededor de cero y mantiene varianza aproximadamente constante.

Chapter 5

Pronóstico de Series de Tiempo Holt-Winters

5.1 Aplicar el modelo de Holt-Winters

Dado que la estacionalidad parece mantenerse relativamente constante en magni-



tud, un modelo aditivo podría ser la mejor opción.

5.2 Evaluar el ajuste del modelo

Holt-Winters exponential smoothing with trend and additive seasonal component.

Call:

```
HoltWinters(x = ts_log_diff, seasonal = "additive")
```

Smoothing parameters:

alpha: 0.002485839

beta : 0.002304457

gamma: 0.3500246

Coefficients:

```

      [,1]
a    1.089413e-03
b    2.932241e-07
s1   -6.006596e-03
s2    1.246027e-03
s3   -8.027069e-03
s4   -2.008704e-03
s5    2.991473e-04
s6   -8.319845e-04
s7   -8.802151e-05
s8   -2.843903e-05
s9   -4.982854e-03
s10  -2.517230e-03
s11  -2.391878e-03
s12  -5.668210e-03
s13  -1.517069e-03
s14   4.203068e-03
s15  -5.860747e-03
s16  -4.513237e-03
s17  -6.195080e-03
s18   2.270634e-03
s19  -9.076049e-04
s20   1.097961e-03
s21  -4.155383e-04
s22   1.418486e-03
s23   2.978348e-03
s24   1.081771e-03
s25   2.798766e-03
s26   2.399658e-03
s27   8.182494e-04
s28   4.736225e-03
s29  -3.317307e-03
s30   1.932720e-03

```

s31 3.491386e-03
s32 -5.864551e-03
s33 -2.540030e-03
s34 -3.128440e-03
s35 1.668221e-04
s36 4.548463e-03
s37 -8.277647e-03
s38 6.471696e-03
s39 3.618264e-03
s40 -5.832373e-03
s41 3.544630e-03
s42 6.176063e-04
s43 3.768946e-03
s44 3.233909e-03
s45 -8.607834e-03
s46 1.886078e-03
s47 -4.186039e-03
s48 -4.515139e-03
s49 -4.135955e-03
s50 -6.368050e-03
s51 -8.977087e-04
s52 -3.290024e-03
s53 1.113716e-03
s54 -3.342337e-03
s55 3.626755e-03
s56 -3.965273e-04
s57 -2.075680e-03
s58 -2.754280e-03
s59 -1.405891e-03
s60 4.118341e-03
s61 4.136166e-03
s62 5.349444e-04
s63 -1.192350e-04
s64 3.438841e-03
s65 -8.287332e-04
s66 -6.952767e-03
s67 -2.787879e-04
s68 -1.830619e-03
s69 1.436565e-03
s70 6.209574e-04
s71 -5.218110e-04
s72 3.209954e-03
s73 -1.704215e-03
s74 -1.688774e-03
s75 2.952404e-04
s76 -3.293497e-03

24CHAPTER 5. PRONÓSTICO DE SERIES DE TIEMPO HOLT-WINTERS

s77 -4.826419e-03
s78 -2.566117e-03
s79 -4.163923e-03
s80 -5.329070e-03
s81 -2.842959e-03
s82 -6.989766e-03
s83 -1.787856e-03
s84 -2.049335e-03
s85 1.667841e-03
s86 4.879011e-03
s87 4.247008e-03
s88 -3.933419e-04
s89 3.012296e-05
s90 -5.543990e-03
s91 6.826864e-03
s92 8.567619e-05
s93 -2.883496e-04
s94 4.622209e-03
s95 5.927811e-03
s96 1.775474e-03
s97 8.635489e-04
s98 -1.558136e-03
s99 -3.130259e-04
s100 -1.621674e-03
s101 1.923294e-03
s102 -1.312027e-03
s103 -3.636532e-04
s104 -3.493332e-03
s105 3.553864e-03
s106 3.928525e-03
s107 4.448884e-06
s108 -4.001756e-03
s109 4.056982e-04
s110 -6.927393e-03
s111 1.478844e-05
s112 -4.999524e-03
s113 -3.199070e-03
s114 3.233633e-03
s115 6.957504e-04
s116 1.863936e-03
s117 -4.423341e-04
s118 1.509581e-03
s119 2.021815e-03
s120 -1.846520e-03
s121 -8.005496e-04
s122 1.547061e-03

s123 7.182702e-04
s124 3.714035e-03
s125 -4.027189e-03
s126 5.717808e-03
s127 1.090861e-03
s128 -6.418397e-03
s129 -6.786928e-03
s130 -2.867290e-04
s131 6.528340e-05
s132 -6.009571e-03
s133 -6.327125e-03
s134 -2.976976e-04
s135 -4.604251e-03
s136 6.340743e-03
s137 -3.164186e-03
s138 -1.556197e-03
s139 -2.462869e-04
s140 1.099738e-03
s141 1.735485e-03
s142 -5.319717e-04
s143 -3.608170e-03
s144 1.684462e-03
s145 -1.790658e-03
s146 -3.481895e-03
s147 -1.779749e-03
s148 5.323218e-04
s149 -6.065902e-03
s150 1.716859e-03
s151 1.219301e-03
s152 -1.874268e-04
s153 3.829110e-04
s154 -4.783010e-03
s155 1.612731e-05
s156 2.364233e-03
s157 -2.213734e-03
s158 -5.597966e-03
s159 -3.821089e-03
s160 -1.373256e-03
s161 -1.532013e-03
s162 -1.285978e-03
s163 -8.144388e-04
s164 -5.205727e-04
s165 -6.249899e-03
s166 -4.720708e-04
s167 -1.068796e-03
s168 4.517868e-03

s169 -6.817660e-04
s170 -1.010070e-03
s171 1.062472e-03
s172 -1.666314e-03
s173 -1.761655e-03
s174 -4.016522e-03
s175 1.751336e-03
s176 -2.530273e-03
s177 -2.995931e-03
s178 -1.441361e-03
s179 -1.575449e-03
s180 3.343202e-03
s181 4.673575e-04
s182 -2.332107e-03
s183 -5.178601e-04
s184 3.990410e-04
s185 -2.133255e-03
s186 -2.094731e-03
s187 -3.896340e-04
s188 1.691047e-03
s189 3.578948e-03
s190 3.145779e-03
s191 9.474957e-04
s192 1.053631e-02
s193 6.194174e-03
s194 3.225156e-03
s195 -2.621365e-04
s196 -5.642724e-03
s197 -3.521495e-03
s198 1.971002e-03
s199 -1.263471e-03
s200 -4.996198e-03
s201 1.445967e-03
s202 -1.776308e-03
s203 -2.344029e-03
s204 1.617864e-03
s205 1.496596e-03
s206 3.895873e-04
s207 1.367554e-03
s208 6.668821e-04
s209 7.164653e-03
s210 6.009623e-04
s211 4.941777e-03
s212 1.448600e-03
s213 2.806936e-04
s214 3.264814e-03

s215 1.906557e-03
s216 3.418660e-03
s217 1.675327e-03
s218 -4.675610e-04
s219 1.636577e-03
s220 1.025650e-03
s221 4.536027e-03
s222 -7.222599e-03
s223 1.978078e-03
s224 4.081899e-04
s225 -8.286500e-03
s226 -3.140769e-03
s227 -1.379760e-03
s228 1.154232e-03
s229 2.159571e-03
s230 -9.453017e-04
s231 -7.979058e-03
s232 2.316149e-03
s233 1.598635e-03
s234 3.908913e-03
s235 -2.312142e-04
s236 -2.748607e-03
s237 -2.734734e-03
s238 2.348458e-03
s239 4.225311e-03
s240 -3.015748e-03
s241 1.325424e-03
s242 5.357783e-03
s243 -2.807670e-03
s244 3.766172e-04
s245 2.572036e-03
s246 -2.820223e-03
s247 -1.376490e-03
s248 -8.239365e-03
s249 -4.164638e-03
s250 4.483667e-03
s251 2.821301e-03
s252 -7.563843e-04
s253 -4.815051e-03
s254 -1.482879e-03
s255 -6.479020e-04
s256 1.904108e-04
s257 7.269574e-03
s258 -1.332769e-03
s259 -1.267300e-02
s260 1.151918e-03

s261 3.742435e-03
s262 -1.276083e-03
s263 -2.962657e-03
s264 1.202684e-03
s265 -5.404705e-03
s266 -1.201425e-03
s267 -4.251649e-04
s268 1.224813e-03
s269 -1.556155e-03
s270 -4.681736e-04
s271 -2.782047e-04
s272 5.754108e-04
s273 3.111046e-03
s274 -1.026666e-03
s275 -6.760200e-04
s276 4.071437e-04
s277 4.175353e-03
s278 8.792565e-04
s279 5.073616e-03
s280 -7.421275e-03
s281 1.774829e-03
s282 6.881177e-04
s283 3.107676e-03
s284 -2.868630e-04
s285 6.902304e-05
s286 -1.576864e-03
s287 -6.977841e-03
s288 -1.431227e-03
s289 -3.422035e-03
s290 2.303711e-04
s291 -2.099472e-02
s292 -1.913143e-03
s293 -1.018591e-02
s294 -3.793987e-04
s295 -3.440800e-03
s296 3.155613e-03
s297 6.781983e-03
s298 -4.108567e-04
s299 -7.199217e-04
s300 -2.394237e-03
s301 -2.883362e-03
s302 -2.214664e-03
s303 4.433837e-03
s304 5.107056e-03
s305 1.241961e-02
s306 1.367940e-03

s307 -1.945525e-03
s308 2.441708e-03
s309 4.906486e-03
s310 -9.646508e-04
s311 -2.485936e-03
s312 -3.654577e-03
s313 5.801343e-03
s314 5.102399e-04
s315 -4.792061e-03
s316 2.043459e-03
s317 1.541670e-03
s318 -3.122704e-03
s319 -2.867022e-03
s320 -3.901920e-04
s321 1.300472e-03
s322 4.471014e-03
s323 -1.906607e-03
s324 -9.640947e-04
s325 4.372890e-03
s326 2.069463e-03
s327 5.685469e-03
s328 1.156968e-03
s329 -1.134836e-03
s330 -1.904866e-03
s331 6.317813e-04
s332 4.595586e-04
s333 -1.184284e-03
s334 -2.263029e-03
s335 1.389792e-03
s336 2.296295e-04
s337 -1.289288e-03
s338 -9.413028e-04
s339 -3.015608e-03
s340 6.278056e-03
s341 1.036939e-03
s342 -2.959538e-05
s343 -2.879698e-03
s344 -1.353353e-03
s345 -7.789647e-04
s346 2.896824e-04
s347 2.471600e-03
s348 -1.098229e-03
s349 2.362386e-03
s350 -3.925777e-03
s351 4.200022e-04
s352 2.197899e-03

```


s353  5.045656e-03
s354  2.037612e-03
s355 -3.418948e-03
s356  3.011355e-04
s357 -8.320141e-04
s358  4.497465e-04
s359  1.889811e-03
s360  1.505183e-03
s361 -1.171691e-03
s362  2.253164e-04
s363 -2.040684e-03
s364 -2.479558e-04
s365 -6.832495e-03

```

- $\alpha = 0.0025$: Indica que la serie da muy poca importancia a los valores recientes en el suavizamiento. Podría ser porque la serie ya está bastante estable después de la transformación.
- $\beta = 0.0023$: La tendencia es muy baja, lo que indica que el modelo no detecta un crecimiento claro después de la diferenciación.
- $\gamma = 0.3500 \rightarrow$ La componente estacional tiene moderada importancia, lo que confirma que el precio del oro muestra fluctuaciones repetitivas

5.3 Pronostico con Holt-Winters


Pronóstico Holt-Winters para los próximos días



La línea roja indica el ajuste del modelo sobre la serie temporal. El modelo

captura bastante bien la variabilidad

5.4 Aplicación de suavizado exponencial simple



Este método da más peso a los valores recientes, lo que ayuda a capturar cambios sin reaccionar bruscamente a fluctuaciones aleatorias. El modelo Holt-Winters añade tendencia y estacionalidad, mientras que el suavizamiento exponencial simple solo suaviza la serie.

5.5 Comparación de modelos

Calcular el error del modelo Holt-Winters

	ME	RMSE	MAE	MPE	MAPE	ACF1	Theil's U
Test set	-0.0001721535	0.009329245	0.006690136	NaN	Inf	-0.02887819	NaN

Calcular el error del Suavizamiento Exponencial Simple

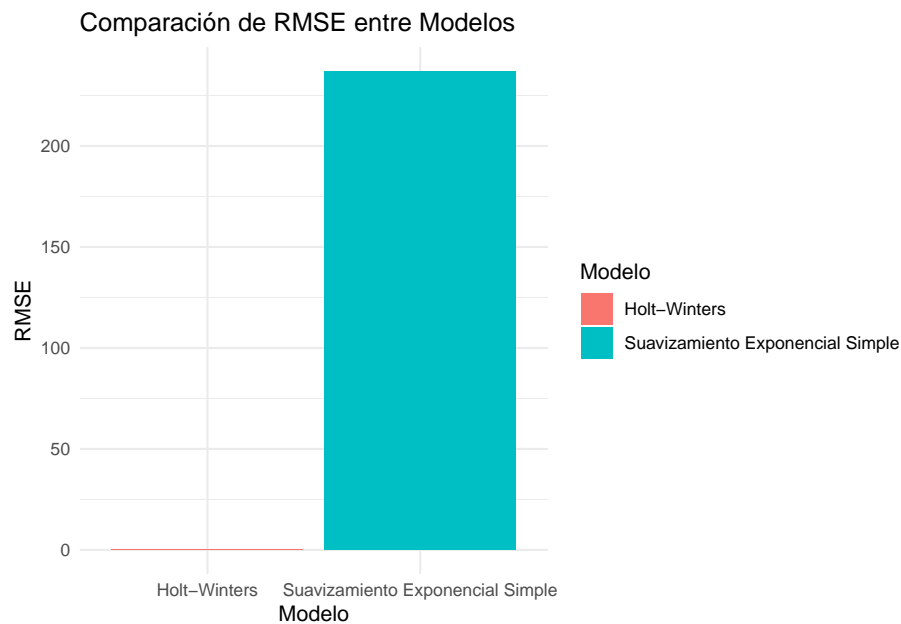
	ME	RMSE	MAE	MPE	MAPE	ACF1	Theil's U
Test set	17.38552	353.6919	237.0729	0.03154244	0.5845796	-0.004346762	0.999267

	Modelo	MAE	RMSE
1	Holt-Winters	9.329245e-03	6.690136e-03
2	Suavizamiento Exponencial Simple	3.536919e+02	2.370729e+02

RMSE: 353.69 en modelo SAS, el modelo no ajusta bien la variabilidad de la serie.

MAE: 237.07 También más alto en modelo SAS, indicando errores más grandes en la predicción.

5.6 Conclusiones



- Holt-Winters tiene un desempeño mucho mejor en términos de error.
- SES muestra un error muy alto, lo que indica que no captura bien la estructura de la serie. Esto es lógico, ya que el suavizamiento exponencial simple no considera estacionalidad ni tendencia, mientras que Holt-Winters sí lo hace.

Chapter 6

Pronóstico con modelo ARIMA

```
Series: serie_ts  
ARIMA(5,2,0)
```

```
Coefficients:
```

	ar1	ar2	ar3	ar4	ar5
	-0.8659	-0.6273	-0.4565	-0.3060	-0.1475
s.e.	0.0187	0.0242	0.0255	0.0242	0.0188

```
sigma^2 = 145160: log likelihood = -20640.28  
AIC=41292.57 AICc=41292.6 BIC=41328.2
```

```
Training set error measures:
```

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.7881241	380.5229	256.2009	-0.001422517	0.6356454	0.04017145

```
ACF1
```

```
Training set -0.01683052
```

```
[1] "AIC: 41292.5656990829"
```


```
[1] "BIC: 41328.1985125718"
```

- El AIC ayuda a comparar modelos—cuanto más bajo, mejor el ajuste con menos complejidad.
- BIC (Bayesian Information Criterion): Similar a AIC, pero penaliza más la complejidad del modelo. Un BIC menor indica que el modelo es más parsimonioso (no sobreajustado).
- RMSE (Root Mean Squared Error): Mide cuánto se desvían las predicciones de los valores reales. Menor RMSE indica mejor precisión en el

ajuste. Para referencia, si el precio del oro oscila en miles, un RMSE de 380 puede ser relativamente aceptable.

- MAE (Mean Absolute Error): Indica el promedio de error absoluto en la predicción
- MAPE (Mean Absolute Percentage Error): Evalúa qué tan bien el modelo predice en términos porcentuales. El modelo tiene buena precisión, con MAPE bajo y errores moderados (RMSE y MAE).
- AIC y BIC sugieren que el modelo es competitivo


Pronóstico ARIMA del Precio del Oro



El modelo predice la evolución del precio del oro basándose en patrones pasados. Dado que $ARIMA(5,2,0)$ usa diferenciación de segundo orden, la predicción busca capturar cambios en la tasa de crecimiento en lugar de los valores absolutos.

Chapter 7

Algoritmo de Facebook's Prophet



Recordemos que la serie del precio del oro:

1. Tiene una tendencia clara, con un crecimiento acelerado en ciertos periodos.
2. Muestra estacionalidad, por lo que hay patrones repetitivos a lo largo del tiempo

3. Al diferenciarla y aplicar transformación logarítmica, la serie se volvió estacionaria

Una regresión clásica funciona bien cuando hay una relación lineal y estable entre las variables, sin embargo, en casos como estos donde las series temporales tienen tendencia y estacionalidad, la regresión simple no captura bien los patrones de la serie.

Esta gráfica representa una serie temporal con datos dispersos y una curva de ajuste dada por el algoritmo de Facebook's Prophet (línea azul).

Vemos que la tendencia se mantiene en valores cercanos a cero, lo que significa que después de la transformación logarítmica y diferenciación, los movimientos del precio del oro son más estacionarios y predecibles.

En conclusión, usar el método Facebook's prophet es adecuado ya que la serie tiene patrones cíclicos y con este algoritmo se captura mejor la evolución de la serie.

Call:

```
lm(formula = y ~ ds, data = df_prophet)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.061581	-0.004095	0.000049	0.004113	0.051570

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.785e-03	2.465e-03	-1.535	0.1248
ds	2.287e-07	1.364e-07	1.677	0.0936

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.00829 on 2803 degrees of freedom


Multiple R-squared: 0.001003, Adjusted R-squared: 0.0006462

F-statistic: 2.813 on 1 and 2803 DF, p-value: 0.09361

Vemos que el p-valor no es menor que 0.05 para una regresión lineal simple por lo que no es altamente significativa y no capta bien la estructura de la serie.

Chapter 8

Redes Neuronales



	Modelo	MAE	RMSE
1	ELMAN	0.005490801	0.007620683
2	JORDAN	0.005701307	0.007939065

- MAE (Mean Absolute Error): Mide el error promedio absoluto entre las predicciones y los valores reales. ELMAN tiene un MAE ligeramente menor, lo que implica que, en promedio, sus predicciones están un poco más cerca de los valores reales.
- RMSE (Root Mean Square Error): Penaliza más los errores grandes. Aquí

también ELMAN muestra mejor desempeño con un valor más bajo, lo que sugiere menor variabilidad en los errores.

Aunque las diferencias son pequeñas, el modelo ELMAN muestra una mejor capacidad de generalización sobre los datos de entrenamiento. Esto sugiere que su arquitectura, con estados de contexto conectados a las entradas, logra capturar secuencias temporales con mayor precisión que JORDAN, cuyo contexto se retroalimenta desde la salida.

El nivel de error es muy bajo, lo cual habla bien del preprocesamiento y la naturaleza del problema. La serie logarítmica diferenciada se comporta de manera predecible para este tipo de modelos.

Chapter 9

Fuentes

- Dataset: <https://www.kaggle.com/datasets/nisargchodavadiya/daily-gold-price-20152021-time-series>